

# 基于心电图的心肌梗死智能辅助诊断方法研究综述



韩闯<sup>1</sup>, 阙文戈<sup>2</sup>, 王治忠<sup>3</sup>, 王松伟<sup>3</sup>, 李艳婷<sup>1</sup> 综述 师丽<sup>2</sup> 审校

1. 郑州轻工业大学 计算机与通信工程学院 (郑州 450000)

2. 清华大学 自动化系 (北京 100000)

3. 郑州大学 电气与信息工程学院 (郑州 450000)

**【摘要】** 心肌梗死(心梗)具有致死率高、突发性和隐蔽性强等特点,临床上存在诊断不及时、误诊和漏诊等问题。心电图检查是诊断心梗最简单和快速的方法,开展基于心电图的心梗智能辅助研究具有重要意义。本文首先介绍心梗的病理生理机制及其心电图的特征性改变;在此基础上,分别综述了心电图特征点提取与形态识别方法、基于机器学习和深度学习的心梗辅助诊断方法,并着重对比分析了不同方法所用模型、数据集和数据量、导联数和输入模式、模型评估方式和效果,最后从心梗数据增强、心电图特征点提取、动态特征提取、模型泛化性与临床可解释性等方面归纳目前存在的问题并对发展趋势进行展望,可望为心梗智能辅助诊断等相关领域的科研工作者提供参考。

**【关键词】** 心电图;心肌梗死;智能辅助诊断;特征提取;机器学习

## A review on intelligent auxiliary diagnosis methods based on electrocardiograms for myocardial infarction

HAN Chuang<sup>1</sup>, QUE Wenge<sup>2</sup>, WANG Zhizhong<sup>3</sup>, WANG Songwei<sup>3</sup>, LI Yanting<sup>1</sup>, SHI Li<sup>2</sup>

1. School of Computer and Communication Engineering, Zhengzhou University of Light Industry, Zhengzhou 450000, P. R. China

2. Department of Automation, Tsinghua university, Beijing 100000, P. R. China

3. School of Electrical and Information Engineering, Zhengzhou University, Zhengzhou 450000, P. R. China

Corresponding author: SHI Li, Email: zzushi@126.com

**【Abstract】** Myocardial infarction (MI) has the characteristics of high mortality rate, strong suddenness and invisibility. There are problems such as the delayed diagnosis, misdiagnosis and missed diagnosis in clinical practice. Electrocardiogram (ECG) examination is the simplest and fastest way to diagnose MI. The research on MI intelligent auxiliary diagnosis based on ECG is of great significance. On the basis of the pathophysiological mechanism of MI and characteristic changes in ECG, feature point extraction and morphology recognition of ECG, along with intelligent auxiliary diagnosis method of MI based on machine learning and deep learning are all summarized. The models, datasets, the number of ECG, the number of leads, input modes, evaluation methods and effects of different methods are compared. Finally, future research directions and development trends are pointed out, including data enhancement of MI, feature points and dynamic features extraction of ECG, the generalization and clinical interpretability of models, which are expected to provide references for researchers in related fields of MI intelligent auxiliary diagnosis.

**【Key words】** Electrocardiogram; Myocardial infarction; Intelligent auxiliary diagnosis; Feature extraction; Machine learning

## 0 引言

根据《中国心血管健康与疾病报告 2021》显

示,冠心病患病人数约 1 139 万,且死亡率呈整体上升趋势<sup>[1]</sup>。心肌梗死(简称:心梗)是冠心病中最具致命性的疾病,死亡率高。冠状动脉(简称:

DOI: 10.7507/1001-5515.202212010

基金项目:国家自然科学基金资助项目(62106233, 62303427);郑州轻工业大学博士基金(2022BSJJZK13)

通信作者: 师丽, Email: zzushi@126.com




图1 心电图的心拍组成示意图

Fig.1 Schematic diagram of electrocardiogram beat

冠脉)造影是心梗诊断的金标准,但其为有创检测;而心电图具有快速及时和简单无创的特点,已成为临床上辅助医生诊断心梗的重要检测手段。临床研究表明,心电图与冠脉造影在对心梗诊断的阳性诊断率上,其差异不具有统计学意义。其中,12导联心电图主要由肢体导联和胸导联组成,其中肢体导联包含I导联、II导联、III导联、加压单极右上肢(augmented voltage right upper limb, AVR)导联、加压单极左上肢(augmented voltage left upper limb, AVL)导联和加压单极左下肢(augmented voltage left lower limb, AVF)导联;胸导联包含V1~V6导联,各导联心电图由周期性变化的心拍组成。如图1所示为心拍组成示意图,主要包含四波和四段,其中四波是指P波、QRS波、T波、U波;四段指PR间期、QRS时间、ST段、QT间期。

开展基于心电图的心梗辅助诊断研究具有重要的理论意义和应用价值。首先,其为心梗的早期预警与精准防治提供了理论参考;其次,准确诊断心梗能够为患者争取最佳治疗时机,保障患者生命安全;然后,心梗辅助诊断系统可减轻心电图室医生的工作负担,辅助偏远地区临床医生判读心电图;最后,高准确率的心梗辅助诊断算法能够服务于穿戴式心电监测设备的研发与智能监护。

心梗智能辅助诊断的核心技术可以归纳为心电图特征提取和分类器设计两个子问题,其中特征提取是指采用各类方法将心电图映射到特征空间,如时域分析、频域分析、时频域分析、基于深度学习自动提取特征的方法等;分类器设计是指在特征空间中构建高度复杂的非线性函数以实现心梗的辅助诊断。心梗患者不同发病时期的心电图QRS波、ST段和T波形态动态变化,且不同梗死病变部位对应心电图多个不同导联,准确检测及定位心梗、确定心梗发病时期,是极具挑战的难题。国

内外研究者开展了大量心梗辅助诊断算法的研究,也有不少研究者对此进行了相关综述。然而,由于其涉及的各个技术环节相对分散,尤其未从不同心梗病期和不同梗死病变部位在心电图的特征性改变方面,系统完整地梳理心梗智能辅助诊断研究中的所有技术环节,致使研究者难以将医生诊断逻辑与策略用于心梗的智能辅助诊断研究中,从而制约了对可解释心梗诊断模型的进一步探究。

因此,本文首先阐述了心梗的病理生理机制及其心电图的特征性变化,然后将心梗辅助诊断技术环节中涉及的心电图特征点提取、形态识别、基于机器学习和深度学习的心梗辅助诊断方法予以综述,最后归纳了现有研究存在的问题并展望了发展趋势,期望对相关读者有所帮助。

## 1 心梗病理生理机制与心电图表现

心梗是冠脉急性、持续性缺血缺氧所引起的心肌坏死,基于冠脉内不稳定的粥样硬化斑块破裂、出血,并引发血栓形成,致血管完全闭塞,从而引发对应的心肌因供血不足逐步发生局部缺血、损伤和坏死。根据心梗发生时心电图ST段是否抬高,分为ST段抬高型心梗和非ST段抬高型心梗,前者本质为冠脉血管完全闭塞,且患者有明显症状,死亡率高,一般采用溶栓治疗;后者的冠脉尚未完全闭塞,随时可能发展为ST段抬高型心梗,且患者无明显症状,心电图无特异性<sup>[2]</sup>。根据心梗病变位置不同,可分为下壁心梗、前间壁心梗、前壁心梗、广泛前壁心梗、高侧壁心梗、前侧壁心梗和心尖部梗死等,如表1所示为不同病变部位梗死对应的心电图导联。

随着心肌缺血、损伤、坏死的发展和恢复,心梗患者的心电图具有一定的演变规律,主要表现为病理性Q波从无到有、ST段抬高到逐步恢复正常、T波高尖到直立及倒置。按照心梗对应心电图波形




图2 心梗的心电图波形演变过程及分期

Fig.2 Evolution of electrocardiogram waves and periods of myocardial infarction

的演变和发病时期,可分为超急性期、急性期、亚急性期和陈旧期。在整个演变过程和各个时期,如图2所示为心电图QRS波、ST段和T波的动态变化过程。首先,超急性期是指发病数分钟到数小时内,大都在2h内,对应心电图先出现高尖的T波,随后较短时间内ST段表现为凹面向上型或斜直型抬高,且无病理性Q波;其次,在数小时到数天内心电图出现病理性Q波,ST段多呈现弓背向上型抬高,严重者出现墓碑型或者巨R型ST段抬高,T波随ST段改变常呈现直立、倒置或正弦波等形态,逐步发展为急性期;然后,在数天到数周内对应的心电图ST段逐步恢复基线,病理性Q波仍存在,T波多倒置,此时处于亚急性期;最后,ST段完全恢复到基线,表现为ST段正常,T波多直立或倒置,此时多发生于心梗发生后数月,且持续数年甚至终身均出现病理性Q波,此时处于陈旧期。

鉴于心梗的临床分析与治疗需求,权威专家又将分期分为:超急性期、急性期和陈旧期,主要是因为亚急性期的ST段是逐渐变化的,不易衡量和准确鉴别,如表2所示为不同心梗病期心电图的表现。

## 2 心梗辅助诊断技术环节

基于心电图的心梗智能辅助诊断关键技术涉及心电图特征点提取、心电图形态识别、基于机器学习和深度学习的心梗辅助诊断方法。其中定位特征点是心电图形态识别和实现心梗辅助诊断的基础,根据心梗病理生理机制与心电图表现等医学知识可知,心梗患者心电图形态与心梗发病时期、

表1 不同病变部位梗死对应的心电图导联

Tab.1 Corresponding leads of electrocardiograms for infarction in different lesions

梗死部位	对应导联	梗死部位	对应导联
下壁	II、III、AVF	高侧壁	I、AVL
前间壁	V1、V2、V3	前侧壁	V5、V6
前壁	V1、V2、V3、V4	心尖部	V3、V4、V5
广泛前壁	V1~V6、I、AVL	侧壁	I、AVL、V5、V6

表2 心梗不同分期心电图表现

Tab.2 Changes of electrocardiograms in different periods of myocardial infarction

分期	超急性期	急性期	陈旧期
T波形态	对称高尖	倒置或直立或正弦波等	直立或倒置
ST段形态	抬高	典型抬高	正常
病理性Q波	无	有	有

病变部位密切相关,是建立可解释心梗辅助诊断模型的基础;建立心梗辅助诊断模型的方法可分为两类,一种是通过设计人工特征,建立基于机器学习的辅助诊断模型;另一种是通过自动学习特征,建立基于深度学习的辅助诊断模型。下面将针对上述所提关键技术进行详细介绍。

### 2.1 心电图特征点提取技术

近年来,随着深度学习技术在机器视觉、语音识别和自然语言处理等领域的成功应用,相关方法也开始逐步用于心电图QRS波和ST—T段检测。He等<sup>[3]</sup>提出了一种基于U型网络(U-net)和双向长短期记忆(long short-term memory, LSTM)网络的QRS波群检测方法,在美国麻省理工学院与贝斯以色列医院(Massachusetts Institute of Technology and Beth Israel Hospital, MIT-BIH)心律失常数据库





上, QRS 波检测的灵敏度为 99.56%。Liu 等<sup>[4]</sup>分别设计了基于密集连接结构和注意力机制的双向 LSTM 网络、基于 U-net 结构的双向 LSTM 网络、基于巢穴 U-net (U-Net++) 结构的双向 LSTM 网络, 并通过集成学习融合上述网络实现 QRS 波的检测; 其研究结果表明, 集成学习的方法可使 QRS 波检测的准确度有所提升。Peimankar 等<sup>[5]</sup>建立了融合一维卷积神经网络 (convolutional neural networks, CNN) 和 LSTM 网络的模型, 并在公开数据库上进行验证, QRS 波起止点的敏感度分别为 99.75% 和 99.36%。刘近贞等<sup>[6]</sup>提出了一种基于分段能量与平稳小波变换的方法对 T 波进行检测, 准确率高于 95%。Londhe 等<sup>[7]</sup>设计了包含一层 CNN、两层双向 LSTM 网络和归一化指数函数 (softmax) 层的心电图特征点检测网络, T 波检测的准确率为 96.17%。Han 等<sup>[8]</sup>提出了一种结合深度学习和电生理知识的多导联心电图特征点提取方法, 并在三个公开数据集上验证了算法的有效性。

综上所述, 传统方法定位 QRS 波和 ST—T 段依赖于固定参数或经验参数, 对信号质量要求高、鲁棒性较差、通用性不强且计算量大; 基于深度学习的特征点提取方法能自动学习 QRS 波和 ST—T 段的波段特征, 具有较强的鲁棒性和稳定性, 对信号质量要求不高, 但仍不能有效表征具有形态和时序复杂性的临床特异心电图波形的变化。在决策定位阶段, 传统方法大都直接使用基于每个特征点属于对应检测点的概率值来判断是否为待检测点, 易造成误检和漏检。

## 2.2 心电图形态识别技术

QRS 波形态复杂多变, 仅少部分研究者对 QRS 波的形态识别进行了探究。周飞燕<sup>[9]</sup>在 QRS 波峰值点识别的基础上, 截取对应候选 QRS 波片段, 并分别建立基于支持向量机 (support vector machine, SVM) 和 CNN 的模型对 rS 型和 qRs 型的 QRS 波进行识别, 两种模型对 rS 型 QRS 波形态识别准确率分别为 98.73% 和 92.98%, 对 qRs 型 QRS 波形态识别准确率分别为 98.31% 和 94.40%。基于 CNN 的 QRS 形态识别效果显著低于 SVM 方法, 主要原因在于 QRS 波形态类别复杂、识别难度大, 且含 QRS 波形态标注的公开数据库极少。杜海曼等<sup>[10]</sup>提取 ST 段面积、均值、参考基线差值、斜率、均方差及 ST 曲面的梯度特征, 在欧洲 ST—T 数据库 (European ST-T database) 上识别五类 ST 段形态的平均准确率为 95.60%。谢佳静等<sup>[11]</sup>提出一种结合切片频率小波变换和 CNN 的 T 波形态识别

算法, 在欧洲 ST—T 数据库上 T 波形态识别准确率为 97.34%。

综上所述, 大部分方法对 ST 段和 T 波形态识别依赖于特征点提取的准确率, 自适应性不强、易受噪声干扰、鲁棒性差、识别准确率一般, 尤其对特异 ST 段和 T 波的形态识别能力差; 基于 SVM 等方法识别 ST 段和 T 波形态时, 所选特征不能完全反映其形态特异变化; 基于深度学习的 ST 段和 T 波形态识别方法需设置候选段, 而候选段的提取依赖于经验参数, 同时无大量含 ST 段和 T 波各类形态标注结果的公开数据集供深度学习训练。

## 2.3 基于机器学习的辅助诊断方法

基于机器学习的心梗辅助诊断方法首先提取特征, 然后对所提特征进行降维, 最后通过各类机器学习算法对心梗进行辅助诊断, 并在公开数据库中验证所提方法的有效性, 绝大部分文献仅研究了是否发生心梗, 并未对心梗的发病时期和梗死发生位置进行探究。上述所提特征包含时域特征<sup>[12]</sup>、频域特征<sup>[13]</sup>、统计特征<sup>[14]</sup>、变换域上的各种统计特征<sup>[15]</sup>、熵特征<sup>[16]</sup>、基于张量分解的三维心电信号特征<sup>[17]</sup>、基于心电向量图的局部时空特征<sup>[18]</sup>、基于心电图的病理特征<sup>[19]</sup>; 采用主成分分析法、局部保留投影、粒子群优化算等对特征进行降维; K 最邻近 (k-nearest neighbor, KNN)、SVM、决策树、朴素贝叶斯、人工神经网络和逻辑回归分析等方法被用于建立基于机器学习的心梗检测模型。Swain 等<sup>[13]</sup>结合斯托克韦尔变换提取心电图的时频域特征。Dohare 等<sup>[14]</sup>提取了包含心电图 P 波、QRS 波和 ST—T 段的振幅、面积、均值、标准差、偏度系数和峰度系数的 220 个特征, 对心梗进行辅助诊断。Fatimah 等<sup>[16]</sup>在对心电图进行傅里叶变换的基础上提取变换系数的熵值和峰度系数等特征。Zhang 等<sup>[17-19]</sup>基于离散小波变换、张量分解, 设计了包含局部信息和时空信息的三阶张量, 实现了基于 12 导联心电图、二维心电图及三维心电向量图的心梗精准定位。Sun 等<sup>[20]</sup>结合确定学习和心电动力学图提取心梗患者心电图的非线性动力学特征, 能够实现心梗的早期诊断。

## 2.4 基于深度学习的辅助诊断方法

一维 CNN<sup>[21-22]</sup>、二维 CNN<sup>[23]</sup>、基于残差网络的 CNN<sup>[24]</sup>、结合残差网络与注意力机制的 CNN<sup>[25]</sup>、基于密集连接网络的 CNN<sup>[26-28]</sup>、自编码网络<sup>[29]</sup>、门控循环单元 (gated recurrent unit, GRU)<sup>[30]</sup>、融合 CNN、LSTM 网络及其变体的网络<sup>[31-33]</sup>、密集连接网络与主动学习相结合的方法<sup>[34]</sup>、残差网络与主动

表 3 部分文献中基于机器学习的心梗辅助诊断方法效果对比

Tab.3 Performance comparison of auxiliary diagnosis methods for myocardial infarction based on machine learning

文献 导联数和数据量	模式	特征和分类器	评估方式和效果
[42] II 导联; 40 182 个患者和 10 546 个正常人	心拍	基于小波分解的模糊熵和雷尼熵; KNN	患者内 (检测): Acc = 99.62%; Se = 99.76%
[43] II、III、AVF 导联; 3 240 个患者和 3 037 个正常人	记录	平稳小波变换、样本熵、归一化子带能量、对数能量熵; SVM	患者间 (检测): Acc = 81.71%; Se = 79.01%; Sp = 79.26%
[14] 12 导联; 60 个患者和 60 个正常人	记录	P 波、QRS 波和 ST-T 段的振幅、面积、均值、标准差、偏度系数、峰度系数; SVM	患者内 (检测): Acc = 96.66%; Se = 96.66%; Sp = 96.66%
[13] 12 导联; 148 个患者和 52 个正常人	心拍	基于斯托克韦尔变换的时频分析; 阈值法	患者内 (检测): Acc = 99.93%; Se = 99.97%
[15] 12 导联; 21 569 个患者和 7 131 个正常人	心拍	基于小波包分解的四分位数极差、皮尔逊相关系数和香农熵; KNN	患者内 (检测): Acc = 99.57%; Se = 99.82%
[16] II 导联; 148 个患者和 80 个正常人	心拍	傅里叶变换、熵、峰度系数; KNN	患者内 (检测): Acc = 99.65%; Se = 99.61%
[17] 12 导联; 50 173 个患者和 10 593 个正常人	心拍	基于张量分解的三阶心电图张量; 决策树	患者内 (检测): Acc = 99.67%; Se = 99.98%

学习相结合的方法<sup>[35]</sup> 等均被用于自动提取心电图特征以实现心梗的诊断。

Prabhakararao 等<sup>[36]</sup> 设计了表征多尺度时间相关性的循环神经网络和注意力模块, 通过确定发病时期实现心梗的早期诊断, 对超急性期心梗、急性期心梗、陈旧期心梗、正常和非心梗检测的平均 F1 值为 97.65%。Tadesse 等<sup>[37]</sup> 提出了一种基于频谱图的时频分析和迁移学习的方法确定心梗的发生时间, 正常、超急性期心梗、急性期心梗和陈旧期心梗检测的受试者操作特征曲线下面积均值分别为 96.7%、82.9%、68.6% 和 73.8%。

Liu 等<sup>[38]</sup> 通过小波分解和三维空间重建方法将 12 导联心电信号转换为图像, 并建立二维 CNN 对心梗进行检测。He 等<sup>[39]</sup> 建立了多分支 CNN, 通过二维心电图向量图实现了基于三维心电图向量图的心梗精准定位。Hao 等<sup>[40]</sup> 采用 12 导联整幅心电图图像作为输入, 设计了基于二维 CNN 的多导联多分支网络对心梗进行检测, 患者间心梗检测的准确率为 94.73%。

Jahmunah 等<sup>[28]</sup> 建立了一维密集连接网络的 CNN 对心梗进行检测和定位, 并使用基于梯度的类激活映射方法分析模型的可解释性。Anand 等<sup>[41]</sup> 建立了基于残差网络的二维 CNN 识别心律失常、心梗和房室肥大, 同时通过计算心电图特征并结合输出的平均边际贡献值对模型进行可视化。上述可解释性方法能够显示异常心电图波形, 为医生提供更加直观的诊断依据。

### 3 模型评估与比较

如表 3 所示为基于机器学习的心梗辅助诊断方法对比<sup>[13-17, 42-43]</sup>; 如表 4 所示为基于深度学习的

心梗辅助诊断方法对比<sup>[22, 25-26, 29, 31, 33, 40, 44]</sup>。下面从所用方法、数据集和数据量、导联数和输入模式、模型评估方式和效果等方面对比分析。

(1) 对比表 3 和表 4 使用的特征和分类器: 基于机器学习的心梗辅助诊断方法主要通过设计人工特征并结合分类器实现心梗的辅助诊断; 而深度学习通过建立多层神经网络表征心梗患者复杂心电图特征。心梗决策逻辑和策略复杂、心梗患者心电图差异大, 现有人工设计特征的方法特征表达能力不强, 不能有效表征不同心梗患者心电图 QRS 波和 ST—T 段的特异性变化。对比基于机器学习的心梗辅助诊断方法, 通过自动学习特征的深度学习对心梗检测的准确率更高。

(2) 对比表 3 和表 4 所用数据集和数据量: 绝大部分文献均使用公开的德国联邦物理技术研究院 (Physikalisch Technische Bundesanstalt, PTB) 数据库验证算法的有效性, 该数据库仅包含 148 个心梗患者和 52 个正常人的 15 导联心电图数据, 少部分研究者使用经扩充的 PTB 大型心电图数据库 (PTB-XL), 其包含心梗患者的心电数据 5 486 条。PTB 数据库规模小, 尤其不同梗死类型的患者数量更少; 而 PTB-XL 数据库中, 心电图的标注结果是属于某类梗死病变部位的概率, 因此数据库中存在大量标注结果不确定的心电图。

(3) 对比表 3 和表 4 所用心电图的导联数和输入模式: 输入的心电图模式包含基于心拍和基于记录两种, 其中基于心拍的模式对应模型的输入为单个导联的单个心拍或多个心拍, 基于记录的模式对应模型的输入为多个导联的单个心拍或多个心拍。根据表 1 和表 2 可知: 不同病变部位梗死和不同病期心梗在心电图的 12 个导联上均有对应性

表 4 部分文献中基于深度学习的心梗辅助诊断方法效果对比

Tab.4 Performance comparison of auxiliary diagnosis methods for myocardial infarction based on deep learning

文献	导联数和数据量	方法	检测和定位	评估方式和效果	
				患者内	患者间
[29]	12 导联; 24 612 个患者和 4 858 个正常人	卷积自编码模型 (记录)	检测和定位	检测: Acc = 99.50%; 定位: Acc = 99.50%	无
[40]	12 导联; 1 557 幅心梗患者心电图图像	基于 CNN 的多导联分支模型 (记录)	检测	无	Acc = 94.73%; Se = 96.41%; Sp = 95.94%
[33]	12 导联; 632 940 个患者和 127 188 个正常人	二维 CNN 和双向 GRU (记录)	检测和定位	检测: Acc = 99.93%; Se = 99.99%; 定位: Acc = 99.11%; Se = 99.02%	检测: Acc = 96.50%; Se = 97.10%; 定位: Acc = 62.94%; Se = 63.97%
[31]	12 导联; 53 712 个患者和 10 638 个正常人	CNN 和双向 LSTM 模型 (记录)	检测	Acc = 99.90%; Se = 99.97%; Sp = 99.54%	Acc = 93.08%; Se = 94.42%; Sp = 86.29%
[22]	12 导联; 6 000 个患者和 1 200 个正常人	多尺度特征级联 CNN (记录)	检测和定位	无	检测: Acc = 94.76%; 定位: Acc = 61.82%
[26]	12 导联; 50 315 个患者和 10 593 个正常人	一维密集连接网络 (记录)	定位	Acc = 99.87%; Se = 99.84%; Sp = 99.98%	无
[25]	11 导联; 50 315 个患者和 570 080 个正常人	多尺度残差网络与注意力机制 (记录)	检测和定位	检测: Acc = 99.98%; Se = 99.94%; 定位: Acc = 99.79%; Se = 99.88%	无
[44]	12 导联; 18 350 个患者和 6 060 个正常人	三维心电图图像 (记录)	检测	Acc = 100.00%; Se = 100.00%; Sp = 100.00%	Acc = 95.65%; Se = 97.34%; Sp = 90.80%

变化,然而很多研究者仅选择患者某个导联或少部分导联的心电图为输入,这种方式不符合医生诊断心梗的逻辑和策略。

(4)对比表 3 和表 4 中模型评估方式和效果,首先需考虑两种分类模式,即患者内分类模式是指所用训练集和测试集中包含相同患者不同时间的心电图,而患者间分类模式是指训练集和测试集中的心电图均来自不同的患者。因为同一患者不同时间的心电图具有相似性,故患者内模式中,同一患者的心电数据同时出现在训练集和测试集中,没有考虑个体差异,测试集中的数据极易被准确识别;而患者间分类模式下,训练集和测试集的心电数据记录无交集,充分考虑了心电图的个体差异,能够有效公正地评估算法的性能。

基于机器学习的心梗辅助诊断方法对患者内心梗检测效果好,对应的准确率 (accuracy, Acc)、敏感度 (sensitivity, Se) 和特异性 (specificity, Sp) 大都超过 99%,仅少部分研究者在患者间模式验证了心梗检测的有效性,准确率和敏感度大都在 90% 以下,几乎无研究者使用机器学习方法评估心梗定期和定位的性能。

对比上述方法,通过自动学习特征的深度学习方法对患者内心梗检测结果有明显提升,患者内心梗定位效果尚可,但在患者间评估模式下心梗定位效果较差,主要原因在于 PTB 数据库中不同梗死病变部位的患者数量少,最多的下壁心梗患者仅

30 人,最少的侧壁心梗和后侧壁心梗患者均为 1 人。

近年来,通过心电大数据诊断或预警各类心脏疾病的方法被广泛应用。Ribeiro 等<sup>[45]</sup>设计了基于残差网络的 CNN,能够识别 6 类心律失常事件,并基于 2 322 513 条心电图对模型进行训练。Zhu 等<sup>[46]</sup>使用 70 692 个患者的 180 112 条 12 导联心电图对 21 类心律失常进行多标签识别,均取得了比临床医生识别结果更高的准确率。上述这些针对疾病诊断或者早期预警研究能取得较好效果的方法,一般都依赖于大数据。

4 总结与展望

本文系统回顾了基于心电图的心梗智能辅助诊断相关研究,并围绕心梗病理生理机制与心电图表现、心梗辅助诊断相关技术环节、模型评估与比较进行了深层次的总结。总体来说,基于心电图的心梗智能辅助诊断研究已取得一定的研究成果,但仍存在一些问题,有待进一步研究解决:

(1)缺乏高质量的心梗患者心电数据。现有公开数据库中,心梗患者的心电数据规模小、标注结果不准确,难以满足开发高准确率心梗智能辅助诊断算法的需求。可行的解决思路为:与医院心电图室开展合作,建立心梗患者标准心电数据库。同时由医生对每条心电数据进行标注,标注结果应包含诊断结果和诊断依据,其中诊断依据为心电图对



应导联 QRS 波、ST 段和 T 波的形态。

(2) 缺乏同一心梗患者在不同病期的动态演变心电数据, 且不同心梗病期的心电数据不均衡。可行的解决思路为: 基于心电图产生原理建立心脏电生理模型, 产生同一患者不同病期的心电图; 建立基于生成对抗网络的心梗数据增强模型, 生成更多的心电图。

(3) 心电图特征点提取准确率仍有待提高。临床上, 心梗常合并心律失常发生, 此类心电图特征点的漏检率和误检率较高。可行的解决思路有: ① 建立基于 U-net 与自注意力机制的特征点提取模型, 表征心拍精细化的形态特征和采样时刻的强时序相关性特征; ② 采用调整不应期和心率范围等方法自适应地修正特征点的位置。

(4) 难以准确识别心梗患者心电图 QRS 波、ST 段和 T 波形态。心梗患者不同病期 QRS 波、ST 段和 T 波形态复杂, 同时按一定的演变规律动态变化, 如何解析心梗患者心电图动态变化规律是极具挑战的科学问题。可行的解决思路为: 结合深度学习和贝叶斯算法识别不同心梗病期心电图 QRS 波、ST 段和 T 波形态。

(5) 心梗检测和定位的准确率仍有待提高。通过设计人工特征实现心梗辅助诊断的方法, 不能有效表征不同病期心梗患者心电图的特异变化, 无法建立泛化能力强、准确率高的心梗辅助诊断模型。可行的解决思路有: ① 结合心电图不同采样点和波段间的空间相关性、各导联间心电数据的时间依赖性建立时空融合模型, 提高心梗检测和定位的准确率; ② 建立结合 CNN 和深度自注意力机制的心梗辅助诊断模型, 能够表征心拍各波段的局部信息和全局信息, 从而学习到更多可区分的心电图特征。

(6) 心梗辅助诊断模型临床可解释性较差。现有基于热力图的心梗辅助诊断方法临床可解释性弱, 不能分析心梗漏诊和误诊发生的原因。可行的解决思路有: ① 结合专家知识量化每一层预测的内在逻辑, 并与心梗患者心电图 QRS 波、ST 段和 T 波关联, 建立一种具有自解释能力的心梗辅助诊断模型; ② 将知识图谱用于心梗智能辅助诊断研究中, 通过知识表示和知识推理技术实现其临床可解释性。

综上所述, 建立高质量的心梗患者心电数据库、设计心梗数据增强模型、准确提取心电图特征点和识别心电图形态、建立具有高准确率和强临床可解释性的心梗辅助诊断模型等均为心梗智能辅助诊断的研究趋势。

## 重要声明

利益冲突声明: 本文全体作者均声明不存在利益冲突。

作者贡献声明: 韩闯为综述主要撰写人, 完成文献资料的整理收集与分析, 以及论文初稿的撰写; 阙文戈和李艳婷参与文献资料分析与论文修改; 王治忠和王松伟参与论文的修改与指导; 师丽参与论文的指导与审核。

## 参考文献

- 1 马丽媛, 王增武, 樊静, 等. 《中国心血管健康与疾病报告2021》要点解读. 中国全科医学, 2022, 25(27): 3331-3346.
- 2 Vogel B, Claessen B E, Arnold S V, *et al.* ST-segment elevation myocardial infarction. *Nature Reviews Disease Primers*, 2019, 5(1): 39.
- 3 He R, Liu Y, Wang K, *et al.* Automatic detection of QRS complexes using dual channels based on U-Net and bidirectional long short-term memory. *IEEE Journal of Biomedical and Health Informatics*, 2021, 25(4): 1052-1061.
- 4 Liu Lingfeng, Bai Baodan, Chen Xinrong, *et al.* Semantic segmentation of QRS complex in single channel ECG with bidirectional LSTM networks. *Journal of Medical Imaging and Health Informatics*, 2020, 10(3): 758-762.
- 5 Peimankar A, Puthusserypady S. DENS-ECG: A deep learning approach for ECG signal delineation. *Expert Systems with Applications*, 2021, 165: 113911.
- 6 刘近贞, 孙利飞, 熊慧, 等. 基于能量分段与平稳小波变换的运动心电图特征波检测算法研究. *生物医学工程学杂志*, 2021, 38(6): 1181-1192.
- 7 Londhe A N, Atulkar M. Semantic segmentation of ECG waves using hybrid channel-mix convolutional and bidirectional LSTM. *Biomedical Signal Processing and Control*, 2021, 63: 102162.
- 8 Han C, Que W, Wang S, *et al.* QRS complexes and T waves localization in multi-lead ECG signals based on deep learning and electrophysiology knowledge. *Expert Systems with Applications*, 2022, 199: 117187.
- 9 周飞燕. 心电图分析的多分类器融合及其评价方法研究. 合肥: 中国科学技术大学, 2017.
- 10 杜海曼, 边婷, 熊鹏, 等. 基于支持向量机多特征融合ST段形态分类. *生物医学工程学杂志*, 2022, 39(4): 702-712.
- 11 谢佳静, 魏守水, 江兴娥, 等. 基于CNN和频率切片小波变换的T波形态分类. *中国生物医学工程学报*, 2021, 40(1): 1-11.
- 12 熊鹏, 齐明锐, 张杰烁, 等. 基于形态学特征的下壁心肌梗死检测. *生物医学工程学杂志*, 2021, 38(1): 65-71.
- 13 Swain S S, Patra D, Singh Y O. Automated detection of myocardial infarction in ECG using modified Stockwell transform and phase distribution pattern from time-frequency analysis. *Biocybernetics and Biomedical Engineering*, 2020, 40(3): 1174-1189.
- 14 Dohare A K, Kumar V, Kumar R. Detection of myocardial infarction in 12 lead ECG using support vector machine. *Applied Soft Computing*, 2018, 64: 138-147.
- 15 Lin Z, Gao Y, Chen Y, *et al.* Automated detection of myocardial infarction using robust features extracted from 12-lead ECG. *Signal, Image and Video Processing*, 2020, 14: 857-865.
- 16 Fatimah B, Singh P, Singhal A, *et al.* Efficient detection of myocardial infarction from single lead ECG signal. *Biomedical Signal Processing and Control*, 2021, 68: 102678.

- 17 Zhang J, Liu M, Xiong P, *et al.* Automated localization of myocardial infarction of image-based multilead ECG tensor with Tucker2 decomposition. *IEEE Transactions on Instrumentation and Measurement*, 2022, 71: 1-15.
- 18 Zhang J, Liu M, Xiong P, *et al.* Automated localization of myocardial infarction from vectorcardiographic via tensor decomposition. *IEEE Transactions on Biomedical Engineering*, 2023, 70(3): 812-823.
- 19 Zhang J, Liu M, Xiong P, *et al.* A multi-dimensional association information analysis approach to automated detection and localization of myocardial infarction. *Engineering Applications of Artificial Intelligence*, 2021, 97: 104092.
- 20 Sun Q, Liang C, Chen T, *et al.* Early detection of myocardial ischemia in 12-lead ECG using deterministic learning and ensemble learning. *Computer Methods and Programs in Biomedicine*, 2022, 226: 107124.
- 21 Acharya U R, Fujita H, Oh S L, *et al.* Application of deep convolutional neural network for automated detection of myocardial infarction using ECG signals. *Information Sciences*, 2017, 415-416: 190-198.
- 22 Jian J Z, Ger T R, Lai H H, *et al.* Detection of myocardial infarction using ECG and multi-scale feature concatenate. *Sensors*, 2021, 21(5): 1906.
- 23 Pan W, An Y, Guan Y, *et al.* MCA-net: a multi-task channel attention network for myocardial infarction detection and location using 12-lead ECGs. *Computers in Biology and Medicine*, 2022, 150: 106199.
- 24 Han C, Shi L. ML-ResNet: a novel network to detect and locate myocardial infarction using 12 leads ECG. *Computer Methods and Programs in Biomedicine*, 2020, 185: 105138.
- 25 Cao Y, Liu W, Zhang S, *et al.* Detection and localization of myocardial infarction based on multi-scale ResNet and attention mechanism. *Frontiers in Physiology*, 2022, 13: 783184.
- 26 Xiong P, Xue Y, Zhang J, *et al.* Localization of myocardial infarction with multi-lead ECG based on DenseNet. *Computer Methods and Programs in Biomedicine*, 2021, 203: 106024.
- 27 熊鹏, 薛彦平, 刘明, 等. 基于密集连接卷积神经网络的下壁心肌梗死检测. *生物医学工程学杂志*, 2020, 37(1): 142-149.
- 28 Jahmunah V, Ng E Y K, Tan R S, *et al.* Explainable detection of myocardial infarction using deep learning models with Grad-CAM technique on ECG signals. *Computers in Biology and Medicine*, 2022, 146: 105550.
- 29 Sugimoto K, Kon Y, Lee S, *et al.* Detection and localization of myocardial infarction based on a convolutional autoencoder. *Knowledge-Based Systems*, 2019, 178: 123-131.
- 30 徐文畅, 何文明, 游斌权, 等. 基于形态特征提取的急性下壁心肌梗死BiLSTM网络辅助诊断算法. *电子与信息学报*, 2021, 43(9): 2561-2568.
- 31 Liu W, Wang F, Huang Q, *et al.* MFB-CBRNN: a hybrid network for MI detection using 12-lead ECGs. *IEEE Journal of Biomedical and Health Informatics*, 2020, 24(2): 503-514.
- 32 Rai H M, Chatterjee K. Hybrid CNN-LSTM deep learning model and ensemble technique for automatic detection of myocardial infarction using big ECG data. *Applied Intelligence*, 2022, 52(5): 5366-5384.
- 33 Fu L, Lu B, Nie B, *et al.* Hybrid network with attention mechanism for detection and location of myocardial infarction based on 12-lead electrocardiogram signals. *Sensors*, 2020, 20(4): 1020.
- 34 He Z, Yuan S, Zhao J, *et al.* A novel myocardial infarction localization method using multi-branch DenseNet and spatial matching-based active semi-supervised learning. *Information Sciences*, 2022, 606: 649-668.
- 35 He Z, Yuan S, Zhao J, *et al.* A robust myocardial infarction localization system based on multi-branch residual shrinkage network and active learning with clustering. *Biomedical Signal Processing and Control*, 2023, 80: 104238.
- 36 Prabhakararao E, Dandapat S. Myocardial infarction severity stages classification from ECG signals using attentional recurrent neural network. *IEEE Sensors Journal*, 2020, 20(15): 8711-8720.
- 37 Tadesse G A, Javed H, Weldemariam K, *et al.* DeepMI: deep multi-lead ECG fusion for identifying myocardial infarction and its occurrence-time. *Artificial Intelligence in Medicine*, 2021, 121: 102192.
- 38 Liu J, Wang R, Wen B, *et al.* Myocardial infarction detection and localization with electrocardiogram based on convolutional neural network. *Chinese Journal of Electronics*, 2021, 30(5): 833-842.
- 39 He C, Liu M, Xiong P, *et al.* Localization of myocardial infarction using a multi-branch weight sharing network based on 2-D vectorcardiogram. *Engineering Applications of Artificial Intelligence*, 2022, 116: 105428.
- 40 Hao P, Gao X, Li Z, *et al.* Multi-branch fusion network for myocardial infarction screening from 12-lead ECG images. *Computer Methods and Programs in Biomedicine*, 2020, 184: 105286.
- 41 Anand A, Kadian T, Shetty M K, *et al.* Explainable AI decision model for ECG data of cardiac disorders. *Biomedical Signal Processing and Control*, 2022, 75: 103584.
- 42 Sharma M, Tan R S, Acharya U R. A novel automated diagnostic system for classification of myocardial infarction ECG signals using an optimal biorthogonal filter bank. *Computers in Biology and Medicine*, 2018, 102: 341-356.
- 43 Sharma L D, Sunkaria R K. Inferior myocardial infarction detection using stationary wavelet transform and machine learning approach. *Signal, Image and Video Processing*, 2018, 12(2): 199-206.
- 44 Fang R, Lu C C, Chuang C T, *et al.* A visually interpretable detection method combines 3-D ECG with a multi-VGG neural network for myocardial infarction identification. *Computer Methods and Programs in Biomedicine*, 2022, 219: 106762.
- 45 Ribeiro A H, Ribeiro M H, Paixão G M M, *et al.* Automatic diagnosis of the 12-lead ECG using a deep neural network. *Nature Communications*, 2020, 11(1): 1760.
- 46 Zhu H, Cheng C, Yin H, *et al.* Automatic multilabel electrocardiogram diagnosis of heart rhythm or conduction abnormalities with deep learning: a cohort study. *The Lancet Digital Health*, 2020, 2(7): e348-e357.

收稿日期: 2022-12-05 修回日期: 2023-08-22  
 本文编辑: 陈咏竹